LSTM

W zadaniach NLP (Natural Language Processing), takich jak:

- analiza sentymentu,
- tłumaczenie maszynowe,
- generowanie tekstu,
- predykcja kolejnego słowa, potrzebujemy modeli, które rozumieją sekwencję słów, a nie tylko pojedyncze słowa.

Tu właśnie używamy **LSTM** — sieci, która potrafi pamiętać kontekst w czasie (np. zależności gramatyczne lub semantyczne).

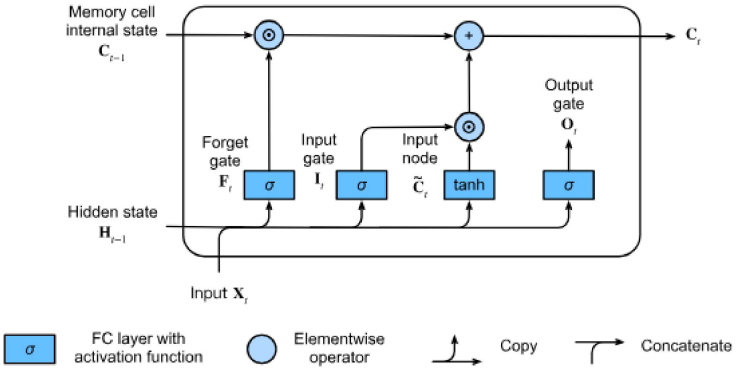
Kiedy używać LSTM?

- gdy sekwencje mają od umiarkowanej do dużej długości i **zależności czasowe są ważne**
- gdy mamy mało danych i nie chcemy używać cięższych modeli (np. transformery - to już niedługo :)), albo chcemy modelu, który działa dobrze na mniejszych zbiorach
- do zadań sekwencyjnych

Kiedy nie używać?

- gdy mamy ogromne zbiory i potrzebujemy najlepszych wyników — transformery (np. BERT) często biją LSTM
- gdy zadanie wymaga globalnych zależności i kontekstów, które lepiej łapią mechanizmy self-attention

Jak zbudowany jest LSTM?



Podstawowy blok LSTM składa się z: stanu komórkowego (cell state) i wewnętrznych bramek:

- **forget gate** (bramka zapominania) — decyduje, które informacje z poprzedniej komórki zignorować
- **input gate** (bramka wejścia) — decyduje, które nowe informacje dodać
- **output gate** (bramka wyjścia) — decyduje, jaka część stanu komórkowego stanie się wyjściem

Przykład - przewidywanie kolejnego słowa w zdaniu

```
!pip install flair
```

```
Downloading segtok-1.5.11-py3-none-any.whl (24 kB)
Downloading transformer_smaller_training_vocab-0.4.2-py3-none-any.whl (14 kB)
Downloading transformers-4.57.6-py3-none-any.whl (12.0 MB)
   ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 12.0/12.0 MB 66.4 MB/s eta 0:00:00
Downloading huggingface_hub-0.36.2-py3-none-any.whl (566 kB)
   ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 566.4/566.4 kB 21.1 MB/s eta 0:00:00
Downloading wikipedia_api-0.16.0-py3-none-any.whl (129 kB)
   ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 129.8/129.8 kB 6.1 MB/s eta 0:00:00
Downloading botocore-1.43.117-py3-none-any.whl (16.1 MB)
   ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 16.1/16.1 MB 59.1 MB/s eta 0:00:00
Downloading jmespath-1.1.0-py3-none-any.whl (20 kB)
Downloading jsonlines-4.0.0-py3-none-any.whl (8.7 kB)
Downloading s3transfer-0.19.3-py3-none-any.whl (90 kB)
   ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 90.3/90.3 kB 5.2 MB/s eta 0:00:00
Downloading tokenizers-0.22.2-cp39-abi3-manylinux_2_17_x86_64.manylinux2014_x86_64.whl (3.3 MB)
   ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 3.3/3.3 MB 67.7 MB/s eta 0:00:00
Downloading intervaltree-3.2.1-py2.py3-none-any.whl (25 kB)
Building wheels for collected packages: langdetect, pptree, sqlitedict, docopt
  Building wheel for langdetect (setup.py) ... done
  Created wheel for langdetect: filename=langdetect-1.0.9-py3-none-any.whl size=993335 sha256=1d901172c8057d89d7f0e79d6b6b
  Stored in directory: /root/.cache/pip/wheels/eb/87/25/2dddf1c94e1786054e25022ec5530bfed52bad86d882999c48
  Building wheel for pptree (setup.py) ... done
  Created wheel for pptree: filename=pptree-3.1-py3-none-any.whl size=4641 sha256=6bb3d13884a594316268bf6766bd496c062ac2f2
  Stored in directory: /root/.cache/pip/wheels/97/5c/d1/a8347c9c986fc222c12240fafdde88e50a72553e19d7517177
  Building wheel for sqlitedict (setup.py) ... done
  Created wheel for sqlitedict: filename=sqlitedict-2.1.0-py3-none-any.whl size=16958 sha256=37e70bc4c94227c2390faa0fc64c8
  Stored in directory: /root/.cache/pip/wheels/56/1e/68/fc282426da812281e81368e59ed19f3edc6d9eef4518dbc41c
  Building wheel for docopt (setup.py) ... done
  Created wheel for docopt: filename=docopt-0.6.2-py2.py3-none-any.whl size=13781 sha256=9793a2b854dedc011ebb23b3fc6a26081
  Stored in directory: /root/.cache/pip/wheels/0b/1d/03/175286677fb5a1341cc3e4755bf8ec0ed08f3329afd67446b0
Successfully built langdetect pptree sqlitedict docopt
Installing collected packages: sqlitedict, pptree, docopt, segtok, langdetect, jsonlines, jmespath, intervaltree, ftfy, de
  Attempting uninstall: huggingface-hub
    Found existing installation: huggingface_hub 1.33.0
    Uninstalling huggingface_hub-1.33.0:
      Successfully uninstalled huggingface_hub-1.33.0
  Attempting uninstall: tokenizers
```

```
import torch
import torch.nn as nn
import torch.optim as optim
from torch.utils.data import Dataset, DataLoader
import numpy as np
import random

from flair.data import Sentence
from flair.embeddings import FlairEmbeddings
```

```
WARNING:torchao.kernel.intmm:Warning: Detected no triton, on systems without Triton certain kernels will not work
```

```
SEED = 42
random.seed(SEED)
torch.manual_seed(SEED)
```

```
<torch._C.Generator at 0x7d9fc810b3f0>
```

Tworzymy słownik

```
sentences = [
  "It was a cold morning in October.",
  "Anna stood by the window, watching the fog rise over the city.",
  "She wrapped her scarf tighter and checked her phone.",
  "A message from Tom appeared: 'Are you ready for today?'.",
  "She smiled, remembering their plan.",
  "They were going to meet at the train station at dawn.",
  "The streets were silent, except for the sound of her footsteps.",
  "As she turned the corner, she saw a figure waiting in the mist.",
  "It was him."
]

# Inicjalizacja embeddingów
embedding = FlairEmbeddings('news-forward')

# dla każdego zdania tworzymy obiekty Sentence
flair_sentences = [Sentence(s) for s in sentences]

# Wydobycie embeddingów słów
for s in flair_sentences:
    embedding.embed(s)

# Zbudowanie słownika słów na podstawie korpusu
words = set(" ".join(sentences).split())
```

```
word2idx = {word: i+1 for i, word in enumerate(words)}  # indeksy od 1 (0 = padding)
idx2word = {i: word for word, i in word2idx.items()}
vocab_size = len(word2idx) + 1

print("Słownik:", word2idx)
print("Rozmiar słownika:", vocab_size)
```

```
2026-10-22 15:29:33,724 https://flair.informatik.hu-berlin.de/resources/embeddings/flair/news-forward-0.4.1.pt not found in
100%|██████████| 69.7M/69.7M [00:02<00:00, 28.3MB/s]2026-10-22 15:29:36,375 copying /tmp/tmp76t4s9z8 to cache at /root/.flai

2026-10-22 15:29:36,484 removing temp file /tmp/tmp76t4s9z8
Słownik: {'She': 1, 'saw': 2, 'over': 3, 'was': 4, "'Are": 5, 'scarf': 6, 'were': 7, 'footsteps.': 8, 'silent,': 9, 'to': 10
Rozmiar słownika: 65
```

Każde słowo dostaje unikalny numer.

Indeks 0 zarezerwowany na padding (wyrównywanie długości sekwencji).

Przewidywanie kolejnego słowa

Będzi trenować lstm w kontekście całej sekwencji, żeby przewidywał nam kolejne słowo. Np: "To był chłodny" -> "poranek"

Tworzymy dataset na podstawie nazszych zdań

```
import torch
import torch.nn as nn
import torch.optim as optim


all_words = " ".join(sentences).split() # wszystkie słowa (to co mamy w słowniku)
seq_length = 4 # będziemy przewidywać piąte słowo na podstawie 4 poprzednich


X_data, y_data = [], []
# sztucznie tworzymy przykłady
for i in range(len(all_words) - seq_length):
  # przesuwamy nasze okienko sekwencji słów po tekście
  X_seq = all_words[i:i+seq_length]
  y_seq = all_words[i+seq_length]
  # nie używamy słów tylko index ze slownika
  X_data.append([word2idx[w] for w in X_seq])
  y_data.append(word2idx[y_seq])


# robimy tensory na których będziemy trenować
X = torch.tensor(X_data)
y = torch.tensor(y_data)


print(f"Sample input: {X_data[0]} -> target: {y_data[0]}")
```

```
Sample input: [56, 4, 31, 62] -> target: 40
```

Na co patrzymy?

Przygotowaliśmy sobie mechanizm że model dostaje 4 słowa (o indeksach 45, 20, 13, 17), a jego zadaniem jest przewidzieć kolejne słowo (o indeksie 5).

Stwórzmy model

Stwórzmy model który od razu zrobi to co ręcznie zrobiliśmy u góry

```
class WordPredictorLSTM(nn.Module):
  def __init__(self, vocab_size, embedding_dim, hidden_dim):
    super().__init__()
    # to nasz embeding modelu - go też będziemy trenować!
    # każde słowo zamieniamy na wektor o długości embedding_dim
    self.embedding = nn.Embedding(vocab_size, embedding_dim)
    # tu jest nasz model :)
    self.lstm = nn.LSTM(embedding_dim, hidden_dim, batch_first=True)
    # mapujemy wynik LSTM na rozkład prawdopodobieństwa z wszystkich słów w słowniku
    self.fc = nn.Linear(hidden_dim, vocab_size)
```

```
  def forward(self, x):
    # x - przyszło do nas słowo (index w słowniku)
    # zmieniamy index na wektor
    embeds = self.embedding(x)
    # przepuszczamy przez lstm
    # out: ukryte stany dla każdego kroku czasowego,
    # h: ostatni ukryty stan (zawiera podsumowanie sekwencji!) - Ważne !,
    # c: wewnętrzny stan pamięci.
    out, (h, c) = self.lstm(embeds)
    # ostatni ukryty stan, zwracamy prawdopodobieństwa - które słowo ma najwyzsze prawdopodobieństwo?
    return self.fc(h[-1])


model_word = WordPredictorLSTM(vocab_size=vocab_size, embedding_dim=100, hidden_dim=128)
criterion = nn.CrossEntropyLoss()
optimizer = optim.Adam(model_word.parameters(), lr=0.001)
```

Trening

```
EPOCHS = 200
for epoch in range(EPOCHS):
  optimizer.zero_grad() # czyścimy gradienty
  output = model_word(X) # przewidywania modelu
  loss = criterion(output, y) # porównujemy przewidywanie vs rzeczywiste słowo
  loss.backward() # liczymy gradienty
  optimizer.step() # aktualizujemy wagi
  if (epoch+1) % 40 == 0:
    print(f"Epoch {epoch+1}/{EPOCHS}, Loss: {loss.item():.4f}")
```

```
Epoch 40/200, Loss: 1.4996
Epoch 80/200, Loss: 0.0828
Epoch 120/200, Loss: 0.0272
Epoch 160/200, Loss: 0.0154
Epoch 200/200, Loss: 0.0102
```

Przetestujmy nasz model! 😼

```
def generate_text(model, seed_text, next_words=8):
  model.eval() # nie aktualizuj wag
  words = seed_text.split() # pierwsze zdanie zamieniamy na listę słów
  for _ in range(next_words): # generujemy tyle kolejnych słów ile chcemy
    seq = [word2idx.get(w, 0) for w in words[-seq_length:]] # zmieniamy na indeksy nasz kontekst, seq_length zdefiniowaliśr
    x = torch.tensor(seq).unsqueeze(0) # tensor o wymiarze (1, długość kontekstu)
    with torch.no_grad():
      output = model(x) # przewidujemy na podstawie otrzymanych 4 słów
      predicted_idx = torch.argmax(output, dim=1).item() # wybieramy jakie słowo ma największe prawdopodobieństwo
      predicted_word = idx2word.get(predicted_idx, '') # indext wybranego słowa -> słowo
      words.append(predicted_word)
  return ' '.join(words) # zwracamy wszystko po kolei (nasza historia)


seed = "It was a cold"
print("Generated continuation:")
print(generate_text(model_word, seed))
```

```
Generated continuation:
It was a cold morning in October. Anna stood by the window,
```

Zadanie

3 pkt

Stwórz sieć LSTM, która przewidzi kolejne zdanie a nie kolejne słowo

Input sentence → Encoder LSTM → Hidden state → Decoder LSTM → Predicted next sentence

UWAGA! Zproponowano szkielet LSTM SeqToSeq - ale jeśli chcesz zrobić to w inny sposób, użyć innych emebedingów itp - śmiało :)

```
sentences = [
    "It was a bright and sunny morning.",
    "The birds chirped happily in the trees.",
    "A cool breeze swept through the streets.",
```

```
    "Children played joyfully in the park.",
    "The cat lounged lazily on the windowsill.",
    "The coffee shop smelled of freshly brewed espresso.",
    "Raindrops pattered softly against the roof.",
    "The sky turned shades of pink and orange at sunset.",
    "A dog barked loudly at a passing car.",
    "The leaves rustled under the feet of walkers.",
    "Smoke rose from the chimney into the crisp air.",
    "The waves crashed rhythmically onto the shore.",
    "A lone cyclist rode along the quiet road.",
    "Flowers bloomed vibrantly in the garden.",
    "The old bookstore had a comforting aroma of paper.",
    "Fog rolled over the hills in the early morning.",
    "A gentle hum of traffic filled the city streets.",
    "The clock struck noon with a resounding chime.",
    "Windows rattled in the wind of the approaching storm.",
    "The bakery displayed an array of fresh pastries.",
    "A distant train whistle echoed through the valley.",
    "Stars twinkled faintly in the darkening sky.",
    "The playground was empty as dusk approached.",
    "A fisherman cast his line into the calm river.",
    "The scent of pine trees lingered in the air.",
    "Clouds gathered ominously over the mountains.",
    "The market buzzed with people and chatter.",
    "A child laughed as a balloon floated away.",
    "The lamp post flickered in the evening gloom.",
    "Shadows stretched long across the empty street.",
    "The fountain gurgled peacefully in the square.",
    "A paper airplane sailed across the classroom.",
    "The dog chased its tail in playful circles.",
    "The train station was crowded with travelers.",
    "Snowflakes drifted silently from the gray sky.",
    "A painter worked diligently on his canvas.",
    "The wind whispered secrets through the trees.",
    "A street musician played a soulful tune.",
    "The river sparkled under the midday sun.",
    "The fire crackled warmly in the hearth.",
    "A cyclist narrowly avoided a puddle on the road.",
    "The library was silent except for turning pages.",
    "The airplane soared high above the clouds.",
    "A butterfly landed delicately on a flower.",
    "The aroma of freshly baked bread filled the kitchen.",
    "The old clock ticked steadily in the hallway.",
    "A cat chased a shadow across the wall.",
    "The garden gate creaked in the evening breeze.",
    "The moon reflected off the still lake.",
    "A boy flew a kite on the open field.",
    "The streets glistened after a sudden rain shower."
]
```

```
# EMBEDINGI
from flair.data import Sentence
from flair.embeddings import TransformerDocumentEmbeddings

embedder = TransformerDocumentEmbeddings('bert-base-uncased')

flair_sentences = [Sentence(s) for s in sentences]
embedder.embed(flair_sentences)

# jeśli tu jest zero to prawdopodobnie coś poszło nie tak :)
print("Embedding pierwszego zdania:", flair_sentences[0].embedding.shape)

# DATASET - sequence to sequence
import torch

embeddings = [s.embedding for s in flair_sentences]

X_seq = torch.stack(embeddings[:-1]).unsqueeze(1)
y_seq = torch.stack(embeddings[1:]).unsqueeze(1)

# jeśli tu jest zero to prawdopodobnie coś poszło nie tak :)
print("X_seq wymiar:", X_seq.shape)

# MODEL
import torch.nn as nn

class Seq2SeqLSTM(nn.Module):
    def __init__(self, input_dim, hidden_dim):
        super().__init__()
        self.encoder = nn.LSTM(input_dim, hidden_dim, batch_first=True)
        self.decoder = nn.LSTM(hidden_dim, hidden_dim, batch_first=True)
        self.fc = nn.Linear(hidden_dim, input_dim)
```

```
    def forward(self, x):
        _, (hidden, cell) = self.encoder(x)

        decoder_input = hidden[-1].unsqueeze(1)
        decoder_out, _ = self.decoder(decoder_input, (hidden, cell))

        out = self.fc(decoder_out)
        return out

input_dim = X_seq.shape[2]
hidden_dim = 64
model_seq = Seq2SeqLSTM(input_dim, hidden_dim)

import torch.optim as optim

criterion = nn.MSELoss()
optimizer = optim.Adam(model_seq.parameters(), lr=0.001)

epochs = 150

for epoch in range(epochs):
    model_seq.train()
    optimizer.zero_grad()

    predictions = model_seq(X_seq)

    loss = criterion(predictions, y_seq)

    loss.backward()
    optimizer.step()

    if (epoch + 1) % 10 == 0:
        print(f"Epoch: {epoch + 1}, Loss: {loss.item():.4f}")
```

```
/usr/local/lib/python3.13/dist-packages/huggingface_hub/utils/_auth.py:94: UserWarning:
The secret `HF_TOKEN` does not exist in your Colab secrets.
To authenticate with the Hugging Face Hub, create a token in your settings tab (https://huggingface.co/settings/tokens), set
You will be able to reuse this secret in all of your notebooks.
Please note that authentication is recommended but still optional to access public models or datasets.
  warnings.warn(
tokenizer_config.json: 100%  48.0/48.0 [00:00<00:00, 3.76kB/s]
config.json: 100%  570/570 [00:00<00:00, 23.4kB/s]
vocab.txt: 232k/? [00:00<00:00, 6.84MB/s]
tokenizer.json: 466k/? [00:00<00:00, 3.76MB/s]
model.safetensors: 100%  440M/440M [00:11<00:00, 39.7MB/s]
Embedding pierwszego zdania: torch.Size([768])
X_seq wymiar: torch.Size([50, 1, 768])
Epoch: 10, Loss: 0.2385
Epoch: 20, Loss: 0.1493
Epoch: 30, Loss: 0.1006
Epoch: 40, Loss: 0.0691
Epoch: 50, Loss: 0.0514
Epoch: 60, Loss: 0.0427
Epoch: 70, Loss: 0.0374
Epoch: 80, Loss: 0.0342
Epoch: 90, Loss: 0.0323
Epoch: 100, Loss: 0.0311
Epoch: 110, Loss: 0.0304
Epoch: 120, Loss: 0.0300
Epoch: 130, Loss: 0.0297
Epoch: 140, Loss: 0.0295
Epoch: 150, Loss: 0.0292
```

UWAGA: **Twój model nie jest modelem generatywnym**! Twój LSTM przewiduje embedding następnego zdania, a my znajdziemy w zbiorze zdań to, które jest najbardziej podobne.

```
import torch
import torch.nn.functional as F

# Podajemy zdanie startowe (ostatnie zdanie z naszej sekwencji)

X_input = torch.tensor(flair_sentences[-1].embedding.cpu().detach().numpy()).unsqueeze(0).unsqueeze(0)

# Model w trybie ewaluacyjnym
model_seq.eval()
with torch.no_grad():
```

```
    predicted_embedding = model_seq(X_input)

print("Wymiary przewidzianego embedingu", predicted_embedding.shape)

# Zamieniamy na 1D tensor
pred_emb = predicted_embedding.squeeze(0).squeeze(0)
# dużo problemów w AI to niezgadzające się shape'y - PAMIĘTAJ PRINTOWAĆ ROZMIAR jesli coś nie gra

# Tworzymy listę embeddingów wszystkich zdań w zbiorze
emb_list = [s.embedding for s in flair_sentences]
# Obliczamy podobieństwo cosinusowe do wszystkich zdań
similarities = [F.cosine_similarity(pred_emb, e, dim=0) for e in emb_list]
# Wybieramy indeks najbardziej podobnego zdania
best_idx = torch.argmax(torch.tensor(similarities))
# wygląda jak niedawne zadanie z labów z wektorami słów, prawda? :)

print('Początek historii: ', flair_sentences[-1])
print("Przewidziane kolejne zdanie (najbliżej w naszym zestawie):")
print(sentences[best_idx])
```

```
Wymiary przewidzianego embedingu torch.Size([1, 1, 768])
Początek historii:  Sentence[9]: "The streets glistened after a sudden rain shower."
Przewidziane kolejne zdanie (najbliżej w naszym zestawie):
The streets glistened after a sudden rain shower.
```